

项目介绍与标注指南

读完本文，你就可以开始标注第一条案例了。

本文面向新成员和标注者，说明项目是什么、资料在哪里、你要填什么、怎么填。

工程细节见 [03-工程实施规范.md](#)，技术问题见 [02-总体架构与问题分析.md](#)。

1. 项目概述

本项目是"高邮二王考据过程知识库"。目标是把王念孙、王引之（二王）的考据过程结构化：记录原文、疑点、证据、方法、推理和结论。不是普通古籍网站，也不是单纯字词索引。

1.1 数据怎么流动：你的工作在哪个环节



你的工作处于全流程核心位置：程序与 AI 只能生成草稿，只有人工标注能把草稿变成可信案例。

1.2 三个数据库：你的工作去了哪里

数据库	是什么	与你有关吗
<code>candidate.db</code>	机器自动跑的候选结果，程序会反复重建	基本不看
<code>annotations.db</code>	人工标注库，你的案例保存在这里	这是你的主战场
<code>main.db</code>	最终展示库，只有审校通过的案例才会进入	你的成果最终会到这里

数据流向：`candidate.db` → `annotations.db` → `main.db` → 网站。你标注并通过审校的案例，最终会出现在项目网站上。

1.3 文档与资料位置

00-项目说明/ 下有六份文档，各有分工：

文件	用途
01-项目介绍与标注指南.md	项目介绍和标注指南（本文）
03-工程实施规范.md	代码规范、数据结构、实现细节（概念不清楚时可查）
06-Git协作指南.md	Git、分支、提交和 PR 基本流程

目录结构：

目录	用途
00-项目说明/	项目说明、工程规范、问题分析
04-项目文献/	原典 Markdown、标注稿、AI JSON（ 优先看 ）
05-归档文献/	DOCX/PDF，用于复核版本、小字和版式等（ 疑难复核 ）

2. 标注任务概述

人工标注的核心任务是建立**可复核的 gold standard**：每一条案例都能回到原文、证据和推理链。

标注是	标注不是
逐案阅读原文后确认来源、引文、关系和推理	简单复制粘贴原文或者 AI 内容
有疑问时标"存疑"，宁可少做	硬凑五步、硬套关系类型
为后续 benchmark 和网站提供可信数据	追求数量而忽略质量

AI 可以生成草稿和提示遗漏，但**人工负责确认**来源、引文、关系和推理是否正确。

每条案例需要覆盖以下要素：

1. 二王论述在哪部书、哪个段落
2. 被考据的原书和原文是什么
3. 被解释/被校的字词（原文对象）和解释后/校正后的字词（训释对象）
4. 两者是什么关系：训释、校勘、通假.....

5. 二王用了哪些证据（必须复制原文，不要意译）
6. 五步推理过程：发疑、设问、取证、释理、结论
7. 用了哪些现代方法概念：声训、书证、义证.....
8. 审校状态：是否通过、仍需核对什么

具体见下一节。

3. 标注 JSON 怎么填（最重要）

下面是可以直接复制的完整 JSON 模板。它保留正式入库需要的字段，但成员最少只需要填 9 处；具体看 3.1。看不懂的字段先留空，不要硬填。

```
1  {
2    "schema_version": "annotation_case.v1",
3    "case_id": "",
4    "case_title": "",
5    "submitted_by": "",
6    "reviewed_by": "",
7    "source_work": "",
8    "source_passage_id": null,
9    "source_location": {
10      "work_title": "",
11      "section_title": "",
12      "entry_title": "",
13      "local_ordinal": null,
14      "archive_file_ref": ""
15    },
16    "target_work": "",
17    "target_text": "",
18    "target_location": {
19      "chapter_or_section": "",
20      "raw_location_note": ""
21    },
22    "term_relations": [
23      {
24        "source_term": "",
25        "target_term": "",
26        "relation_type": null,
27        "relation_subtype": null,
28        "relation_note": ""
29      }
30    ],
```

```
31 "evidences": [  
32   {  
33     "quote": "",  
34     "evidence_role": "",  
35     "source_work": "",  
36     "source_note": "",  
37     "passage_id": null,  
38     "quote_start_char": null,  
39     "quote_end_char": null,  
40     "quote_sha256": null,  
41     "quote_check": "unchecked"  
42   }  
43 ],  
44 "problem_discovery": "",  
45 "research_question": "",  
46 "evidence_collection": "",  
47 "reasoning": "",  
48 "conclusion": "",  
49 "method_profile": {  
50   "concepts": [],  
51   "expressions": [  
52     {  
53       "quote": "",  
54       "passage_id": null,  
55       "mapped_concepts": []  
56     }  
57   ]  
58 },  
59 "machine_result": {  
60   "status": "pending",  
61   "model": "",  
62   "prompt_version": "",  
63   "suggestions": [],  
64   "confidence": null,  
65   "validation": {  
66     "quote_check": "unchecked",  
67     "schema_check": "unchecked",  
68     "enum_check": "unchecked"  
69   }  
70 },  
71 "human_review": {  
72   "status": "pending",  
73   "reviewed_by": "",  
74   "review_result": "",  
75   "notes": ""
```

```

76     },
77     "created_at": "",
78     "updated_at": ""
79 }

```

3.1 必填数据

以下 9 项必须填。只填这 9 项，也可以提交一条最小可用标注。

字段	含义	怎么填	示例
case_title	案例标题	能体现此案例即可	造舟于河
submitted_by	提交者	你的 <姓名>	张三
source_work	二王著作	论述所在的著作	经义述闻
target_work	考据作品	二王考据的对象作品	左传
target_text	考据原文	复制原文，不要改写	造舟于河
term_relations[].source_term	原文对象	被训诂的字词	造
term_relations[].target_term	训释对象	训诂后对应字词	相比次
evidences[].quote	证据引文	忠实原文复制	造、次一声之转
conclusion	结论	最终判断	造应训为比舟、相比次

3.2 建议数据

以下字段建议填。它们能显著提高标注质量，但不确定时可以留空：宁可留空，也不要硬凑。

字段	含义	怎么填	示例
problem_discovery	发疑	（旧说）哪里不稳	旧注造为作舟不合上下文
research_question	设问	改写的可验证问题	造是否应训为相比次
evidence_collection	取证	用了哪些证据材料	声音相转和文献用例为证
reasoning	释理	证据如何推出结论	造、次声近，文义舟相连
evidences[].evidence_role	证据作用	证据在论证中作用	声训、书证、旧注辨驳
evidences[].source_work	证据来源	证据来自哪部书	尔雅

字段	含义	怎么填	示例
evidences[].source_note	位置备注	其他原文位置信息	李巡注、孙炎注
term_relations[].relation_note	关系说明	原文解释训诂内容	造、次一声之转
target_location	对象位置	被考据文本位置	昭公元年

3.3 选填、程序补全与审校字段

以下字段保留是为了后续入库、检索、AI 草稿和人工审校。看得懂可以补一点，看不懂就保持空值。

字段	含义	怎么处理	示例
relation_type	一级关系类型	审校者	训释、校勘、字际关系
relation_subtype	二级关系类型-更细	审校者	声转释义、当作、通假
method_profile.concepts	现代训诂方法概念	审校者	声训、书证、义证
method_profile.expressions	二王方法/现代映射	审校者	一声之转 -> 声训
reviewed_by	审校者	审校者	李四
human_review	人工审校结果	审校者	status: approved
machine_result	机器/AI 草稿结果	成员不填	status: pending
schema_version	标注格式版本	一般不改	annotation_case.v1
case_id	案例唯一编号	程序补全	case_0001
source_passage_id	原文 passage 编号	程序补全	jy_sw_zuozhuan_001
source_location	原文标题路径	知道可填	卷三十-左传下-造舟于河
evidences[].passage_id	证据 passage 编号	程序补全	gy_sz_001
quote_start(end)_char	引文字符起止	程序补全	128 / 135
quote_sha256	引文 hash	程序补全	自动生成
quote_check	引文核验状态	审校者	unchecked/passed/failed
created_at / updated_at	创建和更新时间	程序补全	自动生成

4. 五步推理怎么写

五步固定为五个并列字段（见下表）。**允许缺项，但不允许硬凑**——实在写不出就留空。

步骤	字段	说明	是否必填
发疑	<code>problem_discovery</code>	疑点从哪里来？为什么这里需要考据？	推荐填
设问	<code>research_question</code>	把疑点转成可验证的学术问题	推荐填
取证	<code>evidence_collection</code>	引了哪些材料？用了哪些类型的证据？	推荐填
释理	<code>reasoning</code>	证据如何一步步推出结论？	推荐填
结论	<code>conclusion</code>	最终判断，一句话说清	必填

以《经义述闻》“造舟于河”条为例，二王论证“造”不应释为“为舟/作舟”，而应训为“比舟/相比次”：

五步	内容
发疑	旧注对“造舟”的解释分歧，且“至舟、作舟、诣舟、成舟”等解释与上下文不稳
设问	“造舟于河”的“造”是否应解释为“相比次/比舟”
取证	《说文》“𦨇，古文造”；“造之言曹”“造、次一声之转”； 《左传》《诗经》《尔雅》及李巡、孙炎、薛综等例证
释理	以形索义、因声求义、旁证切合、比较互证，并与文义事理相通
结论	“造舟于河”之“造”应训为“比舟/相比次”

5. 核心概念速查

5.1 relation_type 与 method_profile

概念	回答的问题	字段位置	例子
关系类型	证明了什么	<code>term_relations[].relation_type</code>	训释、通假、误字、当作
方法画像	怎么证明的	<code>method_profile.concepts[]</code>	声训、书证、义证、校勘

同一个结论可以用多种方法证明。例如"造 → 相比次"这个结论（关系类型 = 训释），二王同时用了声训、书证、义证、旧注辨驳、比较互证等多种方法。所以关系和方法必须分开——一个 case 有一个主要关系，但可以有多个方法。

你可以不填 `relation_type` 和 `method_profile`——审校者会最终确认。但理解这个区别有助于你更好地阅读和标注原文。

5.2 relation_type 与 relation_subtype

<code>relation_type</code>	<code>relation_subtype</code>	什么时候用
训释	同义、反训、声转释义、义界	A 被解释为 B
校勘	误字、当作、衍文、脱文、倒文	A 应改作 B，或文本有讹脱衍倒
字际关系	通假、异体、古今字	A 与 B 是字形、字音、用字关系
虚词用法	语气、连词、介词、代词、助词	A 是虚词，其功能被说明
句义解释	句读、语法、上下文解释	重点不是单字，而是整句文义
未定	待核、疑似多类	暂时不能判断

你只需要填一级（如 训释）。二级可由 AI 建议、审校确认。

5.3 certainty 与 status

字段	是什么	可选值	例子
<code>certainty</code>	可信度	确定、较可靠、存疑、待核	证据强但一处待核：较可靠
<code>status</code>	当前状态	草稿、待复核、已审校、已发布	刚提交未审校：草稿

两者不冲突：

- 一个案例可以 `certainty=较可靠` 且 `status=草稿`（证据较强但尚未审校）
- 也可以 `certainty=待核` 且 `status=已审校`（审校者确认此处确实存疑，但流程已走完）

6. AI 使用原则

AI 只能做草稿和辅助检查，**不能替代人工审校**。使用 AI 时请遵守：

- 给定材料，限制范围：**要求 AI 只基于你提供的原文材料回答，不要让它自由发挥。

2. 输出后至少检查五项：

- 引文是否真实出现在原文中
- 来源（书名、篇名）是否写对
- 关系是否写反（谁解释谁，谁校谁）
- 证据是否真的支持结论
- 五步是否硬凑（AI 特别喜欢给每个案例凑满五步——缺项比硬凑好）

3. **AI 输出不能直接入库**：AI 生成的 `machine_result` 只是草稿，必须经过人工确认后才能提交。

7. Benchmark 与标注质量

你可能会问：标注完的案例最后用来干什么？

通过审校的案例会成为 **gold cases**（标准答案），进入 benchmark（评测集）。Benchmark 用来评估 parser 和 AI 的质量——你的标注就是“标准答案”，系统输出会与你的标注做对比。

所以你标注的质量直接决定了整个项目的评估可靠性。 宁可少做案例，也要保证每条案例能回到原文、证据和推理链。

暂时不会训练模型。在积累足够多的高质量 gold cases 之前，所有工作集中在人工标注和审校。

8. 提交前检查

提交案例前，逐条确认：

1. `source_work`（二王出处）与 `target_work`（被考据作品）没搞混。
2. `target_text` 是被考据的核心原文，不是二王的论述。
3. `term_relations` 中 `source_term`（原文对象）和 `target_term`（训释对象）没写反。
4. 每条 evidence 有 `quote`（复制原文）和 `evidence_role`（证据作用）。
5. `relation_type` 是结论关系，不是方法。如果想写“声训”，应该放在 `method_profile.concepts` 里。
6. `method_profile.concepts` 和 `method_profile.expressions` 来自实际材料，不是凭空写的。
7. 五个过程字段：**结论必填**，其余缺项已留空，没有硬凑。
8. AI 生成的内容已经人工核对过。

宁可少做案例，也要保证每条案例能回到原文、证据和推理链。