數智時代古典文獻數字人文研究的三種模式*

楊　浩

提　要：數智時代，以光學字符識別、自然語言處理、知識圖譜及大語言模型爲核心的數字技術正深刻變革着古典文獻的研究範式。本文歸納出三大核心研究模式以推動此變革：首先是“算法驅動的互文性研究”，運用算法系統性掃描和量化文本間的徵引、影響等關係，實現從局部比對到全域關聯的轉變；其次是“AI 賦能的文本分析研究”，利用大模型輔助理解文本深層結構與内涵，探索人機協同的解讀與假設生成；第三是“基於大模型的數據抽取”，通過提示工程或模型微調從非結構化文獻中高效提取結構化信息，爲量化分析和知識發現奠定基礎。這些模式旨在顯著提升研究效率、客觀性和規模，促進研究從“細讀”“遠讀”邁向更高階的“智能讀”。

關鍵詞：大語言模型　研究模式　互文性研究　文本分析　數據抽取

一　引言

在數智時代，數字技術正以前所未有的深度和廣度變革着古典文獻的研究模式。以光學字符識別（OCR）、自然語言處理（NLP）以及知識圖譜（KG）等爲代表的技術突破，爲古典文獻的整理、研究、分析等帶來了足以稱之爲變革性的影響。高精度的古籍 OCR 技術，搭配先進的 NLP 技術，在人機協作下，可以方便地實現古籍圖像文字識別、自動標點、命名實體識別（NER）等，使得對古籍進行大規

* 本文得到東湖高新區國家智能社會治理實驗基地北京大學開放課題“楚文化知識圖譜系統（第一期）”、國家自然科學基金國際重點合作項目“中國儒家學術史知識圖譜構建研究”（72010107003）的支持。

中国知网　https://www.cnki.net

模的批量智能整理成爲可能，已經可以顯著地將海量古籍文獻轉化爲可機讀文本，拓展了研究資料的可獲得性與處理規模。[①] 知識圖譜技術則通過抽取文獻中的實體（人物、地點、時間、官職等）及其關聯關係，構建起結構化的知識網絡，揭示出分散在各類文獻中的複雜歷史脉絡與知識體系。而近年來大語言模型（LLMs）的飛速發展，更爲古典文獻的數字人文研究帶來了新的研究模式。

相較於數智技術所帶來的巨大潛能，傳統古典文獻研究方法在處理大規模的語料和複雜的分析需求時，凸顯出明顯的局限性。例如，依賴人工進行的文本校勘與版本比對，是古典文獻學研究的基石，但其過程耗時費力，效率低下。在進行跨文本、跨作者、跨時代的關聯分析時，傳統的研究方法高度依賴研究者的學識積累與偶然發現，難以系統性地、大規模地捕捉文本間的互文關係、思想傳承或詞彙演變規律。此外，傳統的研究成果多以描述性文本或非結構化注釋呈現，因爲缺乏系統性的結構化數據積累，使得進行量化統計、可視化分析變得頗爲困難，通過對文本中蘊藏的數據進行統計來驗證假設或發現新知變得非常困難，限制着人文研究結論的客觀性與可驗證性。

隨着人工智能技術的不斷發展，模型不僅表現出更高程度的智能，在古典文獻上的表現力也變得越來越强，而且不難想象在未來還會表現出更高的智能水平。因此，古典文獻研究領域和其他許多人文研究領域需要面對一個無法回避的緊要問題：如何有效利用數智化手段，系統性地重構古典文獻的研究模式與方法論？本文之所以提出這一問題，目的在於指出，不僅要利用技術提升現有研究工作的效率與精度（比如加速文獻整理、輔助校勘等古籍整理工作），更要借助算法的計算能力與模型的分析能力，開拓新的研究視野和分析維度。因

① 以“識典古籍”整理平臺爲代表，實現了從古籍圖像 OCR、文字校對、文字對勘、結構整理、標點校對、實體校對等全流程古籍智能整理步驟。參見有關報道：吴丹《數字化，讓古籍觸手可及》，載《人民日報》2024 年 1 月 10 日。

中国知网 https://www.cnki.net

此，研究的關鍵在於設計具體的、可操作的數智化研究模式，充分發揮數據驅動的優勢，促進研究過程的規範化、透明化與可複現性，最終實現古典文獻研究在數智時代的轉型與範式創新。

不難想到，常用的數字人文方法，如詞頻統計、概念抽取、情感分析、社會關係網絡（SNA）、地理信息系統（GIS）等，作爲傳統數字人文方法，在數智時代都可以發揮重要作用。但在人工智能生成内容（AIGC）時代，有哪些研究模式特别能够對古典文獻研究帶來真切與重要的價值？本文嘗試歸納三種具有代表性的核心研究模式，提高到一定的方法論高度，以期推動古典文獻研究的數智化轉型。第一種是“算法驅動的互文性研究”模式，該模式利用文本相似度計算（如編輯距離、TF-IDF、Word Embedding）、序列比對等算法，對大規模古典文獻語料庫進行系統性掃描與比對，旨在自動、高效地發現文本間的徵引、襲用、化用、思想影響等多種互文關係，并對其進行量化分析與可視化呈現，從而揭示文獻生成、傳播與接受的複雜網絡。該研究模式在學術界已經多有采用，是廣泛應用於古典文獻研究的重要的數字人文研究方法。第二種是“AI 賦能的文本分析研究”模式，這仍是可以深入探索的方向，文本分析本身是基於古典文獻展開文學、歷史、哲學、語言等研究的傳統方法，當前則可以利用大語言模型輔助研究者理解文本的深層結構、語義内涵與情感色彩，甚至通過人機協同的方式，探索 AI 在生成式解讀、假設生成、論證輔助等方面的潜力，挑戰并拓展傳統文本解讀的邊界。第三種是“基於大模型的數據抽取”模式，傳統的數據抽取多依賴學者手工標注，準確率雖高，但效率較爲低下，當前則可以利用大語言模型强大的自然語言理解與生成能力，通過設計精巧的提示工程（Prompt Engineering）或進行模型微調（Fine-tuning），實現從非結構化的古典文獻中高效、準確地自動抽取結構化信息（如生平、職官、事件、概念、意象、風格等），爲快速進行數字人文分析與研究提供可量化的原始數據。

在筆者看來，基於當前人工智能水平，這三種研究模式尤爲重

中国知网 https://www.cnki.net

要，值得深入探索與實踐。這三種模式一方面歸納自人文研究自身的規律，另一方面也結合了數字人文理念。“互文性算法分析”和“大模型數據抽取”能够處理前所未有規模的數據，通過量化指標和可視化結果，使研究結論更加客觀、可檢驗，推動研究向更嚴格的實證性研究靠攏。“AI賦能的文本分析”模式則將人工智能技術定位爲激發思考、拓展視野的“智能夥伴”，鼓勵研究者在人機互動中進行更深入的理論探索與思辨。

二　數字人文與古典文獻研究的融合

傳統數字人文方法在古典文獻研究上最成功的實踐要數互文性的方法，該方法也確實對古典文獻研究有較大的助益與推動。互文性理論自誕生以來，始終强調文本之間的互動與語境關聯，一直是古典文獻有關研究的重要理論工具。計算機出現後，互文性理論經歷了由傳統人文分析向計算化模式的重大轉型。借助傳統文本比對、大語言模型等技術，學者可以對大規模古典文獻庫中潛在的互文關係進行自動識别與量化分析。而文本分析本身就是人文研究的重要手段。在數智時代，生成式AI模型的發展爲文本分析的現代轉型提供了嶄新契機。以GPT4、Claude、Gemini、DeepSeek等大語言模型爲代表的人工智能技術，能够基於大樣本數據模擬複雜語言現象和語境理解，在某種程度上實現了對人類“理解”行爲的技術模擬。這種人機“對話”模式能够根據上下文、文本風格和文化脉絡，生成多層級、動態化的批判性解釋，爲古典文獻分析與闡釋注入了技術驅動的多元視角。與此同時，傳統的人文研究極度缺乏結構化數據，難以展開數字人文的研究，僅有的少量數據都是依賴於昂貴的人工標注，其數據量小、結構化程度低，無法支撑大規模跨文本的分析計算。如今，基於大模型的數據抽取方法能够在海量文本中高效識别出人物、事件、時空信息及其複雜關係，并將這些元素自動歸納、結構化和關聯，很大程度上爲各種數字人文方法提供重要的數據生産與利用的能力。

中国知网 https://www.cnki.net

古典文獻數智化研究模式的構建，依賴於一個由關鍵技術組成的工具鏈。其中，相似文本發現算法構成了算法驅動互文性研究的核心，涵蓋了從 TF-IDF、N-gram 匹配、序列比對算法（如 Smith-Waterman 算法的變體），到基於分布式表示的 Word Embedding（如 Word2Vec、GloVe）和句子/文檔向量化技術（如 Sentence-BERT），乃至更複雜的大語言模型。這些算法能够量化文本間的詞彙、語義或結構相似度，從而高效地在大規模語料庫中發掘潛在的徵引、化用關係。近年來，大語言模型技術，特别是其在零樣本（Zero-shot）或少樣本（Few-shot）學習場景下在古典文獻上的應用潛力，爲 AI 賦能的文本分析和數據抽取提供了新的可能。通過精心設計的提示詞工程，研究者可以引導預訓練模型執行特定任務，如識别文本中的特定實體（人名、地名、書名、官職等）、提取事件要素、判斷情感傾向、生成文本摘要、對文本進行分析與闡釋等，很大程度上降低了定制化模型訓練的技術門檻。

儘管數字技術爲古典文獻研究帶來了諸多機遇，但在實際應用中仍面臨一系列嚴峻的技術挑戰，這些挑戰根源於古典文獻本身的複雜性與特殊性。首先，古籍特有的字符與文本形態構成了基礎性障礙，例如異體字、通假字、避諱字等現象非常普遍，且缺乏統一規範，這給古籍圖像 OCR、文本數字化、語料庫對齊以及後續的詞彙分析帶來了巨大困難，顯著影響了數據輸入的準確性與一致性。其次，古漢語的語言特性對自然語言處理技術提出了更高要求，其語法結構、詞彙含義、表達方式與現代漢語差異巨大，且常有省略、倒裝、用典等修辭手法，使得現有的、主要基於現代語言訓練的 NLP 模型在分詞、詞性標注、句法分析、語義理解等任務上表現欠佳，容易産生歧義和錯誤。此外，古典文獻往往缺乏明確的標點符號，增加了文本單元切分的難度，在模型對古典文獻處理之前最好先施以基本的標點。因此，特别是對於傳統計算機算法，要克服這些挑戰，需要研發針對古籍特點的專用算法、構建高質量的古籍語料庫，并探索將語言學、文獻學知識與計算模型更深度融合的技術路徑。在大模型時代，這些困

中国知网 https://www.cnki.net

難得到一定的克服，但仍然有很大提升的空間，鑒於大模型的智能水平的飛速提升的現狀，不難預期古典文獻自身給人工智能技術帶來的困難終究會得到較好的解決。

三 模式一：算法驅動的互文性研究

數字技術的發展，特别是傳統計算機算法與自然語言處理技術的應用，正深刻推動着互文性（Intertextuality）理論研究的計算化轉型。傳統互文性研究，自克里斯蒂娃（Julia Kristeva）[①] 等人提出以來，主要依賴研究者深厚的學養和敏鋭的洞察力，通過精讀文本來發現和闡釋文本間的徵引、模仿、對話或顛覆關係。然而，這種傳統方法在面對海量古典文獻時，往往受限於學者個體的能力，難以進行系統性、大規模的考察。計算方法的引入，使得對大規模語料庫進行自動化、可量化的互文關係探測成爲可能，實現了古典文獻分析範式上從局部比對到全域關聯的根本性轉移。

當前古典文獻的互文性研究已經廣泛采用多種計算方法。一類是基於詞彙相似性與精確/近似文本重用檢測的算法，如 N-gram 方法（包括 Shingling、Skip-gram）通過比較文本間共享的字符或詞序列來識别直接引用或高度相似的段落。序列對齊算法，如 Smith-Waterman、Needleman-Wunsch 以及類 BLAST 算法，通過尋找兩個序列間的最佳匹配（允許插入、删除、替換）來精確識别包含少量增删改的文本重用，李友仁（Paul Vierthaler）針對中文文獻便開發和使用了類 BLAST 算法。[②] 另一類是側重語義相似性與主題互文性檢測的算法，例如基於

① Kristeva J. Sèméiotikè. *Recherches pour une sémanalyse*. Paris: Editions du Seuil, 1969.

② Vierthaler, P., and M. Gelein. "A BLAST-based, Language-agnostic Text Reuse Algorithm with a MARKUS Implementation and Sequence Alignment Optimized for Large Chinese Corpora." *Journal of Cultural Analytics*, 2019.

中国知网 https://www.cnki.net

TF-IDF 的向量空間模型與餘弦相似度計算，[①] 以及能够挖掘潛在主題的 LDA 等主題模型。這些算法往往智能捕捉文本層次的相似性。隨着深度學習的發展，詞嵌入（如 Word2Vec，GloVe）、上下文表示（如 BERT，Sentence-BERT）、對比學習等技術可以將文本映射到高維向量空間，通過計算向量間的距離來判斷語義相似度，能有效處理釋義、典故等深層語義關聯。但這些方法雖然在一定程度上對古典文獻研究有幫助，仍只是淺層的。近年來，大語言模型在精細化互文分析中展現出巨大潛力，不僅能處理詞彙和句法，還能把握語篇結構、語用含義和上下文信息，從而更靈活地發現文本間深層次、非顯性的互文模式，如主題關聯、引徵變形、思想承襲等，而不僅僅停留在詞彙共現或字符串匹配層面，真正爲古典文獻的深入分析與研究帶來嶄新的機遇，亟需加以利用。更爲重要與值得期待的是，隨着模型上下文窗口長度的不斷擴展，大語言模型能够處理更長的文本序列，一次性進行整部或者多部文獻的比對分析，依靠大語言模型更高的智能水平，大大增强了互文發現的深度，將切實助力於古典文獻的分析與研究。

表 1　各種互文性計算方法的比較

代表性算法/技術	核心原理	主要優點	主要局限性	互文性應用場景
N-grams（Shingling，Skip-grams）	比較文本間共享的連續或非連續字符/詞序列	計算簡單，對精確匹配有效	對變體敏感，噪聲多，無法處理語義	查找直接引用，近乎完全相同的段落
序列對齊（Smith-Waterman，Needleman-Wunsch）	尋找兩個序列間的最佳匹配，允許插入、删除、替換	對局部變體有魯棒性，可提供詳細比對信息	需要較長時間計算（尤其全域或無優化時）	精確識别含少量改動的重用，適用於文本複用分析，文獻校勘等

① Deng, Zekun, Hao Yang, and Jun Wang. "A Comparative Study of Shiji and Hanshu from the Perspective of Digital Humanities." *Proceedings of the 21st Chinese National Conference on Computational Linguistics*, 2022, pp. 656—670. https://aclanthology.org/2022.ccl-1.59

中国知网 https://www.cnki.net

續表

代表性算法/技術	核心原理	主要優點	主要局限性	互文性應用場景
類 BLAST 算法	基於種子匹配和擴展的快速啓發式局部對齊	速度較快，適用於大規模語料庫	啓發式的，可能漏掉某些複雜匹配	在大型語料庫中快速定位潛在的文本複用區域
向量空間模型（TF-IDF ＋ Cosine Similarity）	將文檔表示爲詞頻加權的向量，計算向量夾角餘弦值	實現簡單，提供基礎語義度量	忽略詞序，依賴詞彙重叠，難處理同義/多義	識别詞彙分布相似的文檔，初步判斷主題關聯
主題模型（LDA）	發現文本集合中潛在的“主題”分布	能發現不共享關鍵詞但主題相關的文本	主題解釋性可能比較差，對參數敏感	挖掘語料庫主題，識别共享相似主題的文本，發現間接關聯
詞嵌入/上下文表示（Word2Vec，BERT，Sentence-BERT）	將詞/句/文檔映射到語義向量空間	强力捕捉語義關係，有效處理釋義和同義	需大量訓練數據（或依賴預訓練模型），計算成本高，可解釋性差	檢測釋義、典故、主題呼應，計算深層語義相似度
對比學習語義匹配	使用基於神經網絡（如 Transformer）專門訓練用於文本對相似性判斷	對複雜語義關係理解能力强	需要大量標注數據訓練，需要將文本劃分爲句子或篇章進行計算，需要設計超參數，否則會有較多噪聲	高級互文檢測，理解細微語義差别

中国知网　https://www.cnki.net

續表

代表性算法/技術	核心原理	主要優點	主要局限性	互文性應用場景
網絡構建與分析	將文本視爲節點，互文關係視爲邊，應用網絡理論分析	宏觀視角，揭示整體結構、核心節點和社群	依賴底層互文算法檢測精度，大型網絡解釋困難	分析影響網絡、思想傳播、文學傳統演變
大語言模型	强語義理解、生成，少樣本學習	深層理解複雜關係，少樣本學習，輔助解釋，理解力强，可能發現更高階的互文類型	成本高，需要設計精良的提示詞，速度較慢，難以直接處理海量數據，需與其他算法搭配使用	元數據提取，關係驗證，深層語義理解，語境解釋
多算法組合（如：初篩＋精析，向量搜索＋LLM驗證）	整合多算法優勢，初篩＋精析	綜合提升速度、精度、深度，克服單一算法局限	設計複雜，集成調優工作量大	應對複雜挑戰，兼顧初篩與精析，綜合判斷

以下結合筆者參與以及關注到的一些代表性研究對互文性方法進行簡單梳理。比如，該方法能够有效提升傳統文本校勘工作的效率與完備性，特别是在對勘不同文獻中記述相似事件的“異文”方面。鄧澤琨等人在數字人文視角下對《史記》與《漢書》的比較研究中便展示了這一實踐路徑。他們采用了一種融合命名實體作爲外部特徵的文本相似度算法，對《史》《漢》兩書進行段落級别的自動比對，以發現潜在的襲用關係。該方法不僅成功驗證了學者通過傳統人工方法發現的大部分襲用關係，而且新發現了多對先前未被記載的《漢書》襲用《史記》的篇章關係。此外，研究還利用最長公共子序列（LCS）算法自動提取并對齊異文段落間的差異字符，從而實現了對《史》《漢》語言風格差異（如《漢書》更爲簡練，存在顯著的“减字”現

中国知网 https://www.cnki.net

象）的宏觀統計證明與微觀文本例證。[①]

考察某部核心經典在漫長歷史中對後世文獻産生的深遠影響，是思想史研究的重要課題。筆者所在團隊曾選取了上起先秦、下迄晚清的136部儒家典籍作爲語料庫，采用一種近似最長公共子串匹配算法（允許一定差異的編輯距離，以適應古籍流傳中的文字變異），自動識别和提取這些典籍中與《論語》原文在表述或語義上高度相似的文本片段。通過對提取出的近兩萬對平行文本進行多維度（篇目、章節、短語）和歷時性（按朝代分期）的計量統計，研究揭示了《論語》中特定篇目（如《顔淵》《衛靈公》）、章節（如“克己復禮章”“忠恕一貫章”）和短語（如“一以貫之”“己所不欲勿施於人”）在不同歷史時期（尤其宋明理學時期）被後世儒家文獻複用的頻率變化規律。[②]

該方法可借助網絡分析法，直觀呈現大規模文獻集合内部複雜的引用與承襲關係。德龙（Donald Sturgeon）在其對先秦兩漢文獻的文本複用研究中，便采用了此路徑。該研究首先利用算法自動識别出語料庫中超過二十萬條文本複用關係（包括明確徵引與非明確的平行文本），并量化了文本間的複用程度。隨後，研究將每部典籍視爲網絡中的一個節點，將文本複用關係（以量化指標爲權重）視爲連接節點的邊，利用可視化工具和力導向布局算法構建了整個語料庫的文本關係網絡圖。其研究結果清晰地展示了文獻群落的聚集現象，例如道家文獻、史學文獻各自形成了顯著的社群，這些由文本複用關係客觀數據驅動生成的社群結構，在很大程度上印證了傳統的文獻分類。[③] 北京大學數字人文研究中心團隊也借助對比學習方法計算大規模語料上

---

① Deng, Zekun, Hao Yang, and Jun Wang. “A Comparative Study of Shiji and Hanshu from the Perspective of Digital Humanities.” *Proceedings of the 21st Chinese National Conference on Computational Linguistics*, 2022, pp. 656—670. https://aclanthology.org/2022.ccl-1.59

② 楊浩，李佳純，王軍等《〈論語〉在中國歷代儒家典籍中的文本複用與互文分析》，載《中外文化與文論》第56輯，成都：四川大學出版社，2024年版，第174—192頁。

③ Sturgeon, D. “Unsupervised identification of text reuse in early Chinese literature.” *Digital Scholarship in the Humanities*, vol. 33, no. 3, 2018, pp. 670—684. https://doi.org/10.1093/llc/fqx024

中国知网 https://www.cnki.net

的互文聯繫强度，分析思想文化的源流與演變。[①]

除了直接的文本複用，文化元素的傳承與影響往往體現在更深層次的語義關聯上，即使表層文字差異較大。例如，“楚文化知識圖譜系統”的建設直接采用這一路徑，實現了一個很簡單的文化溯源功能。在該系統中，對於《莊子》《楚辭》等代表性楚文化文獻，不僅處理其原文，還利用大模型對其文本進行解釋，并將這些對原文理解的解釋性文本轉化爲句子向量。當用户輸入一個與楚文化相關的概念、主題或元素進行檢索時，系統可以將輸入同樣轉化爲向量，并在解釋向量空間中進行相似度匹配，從而能够超越字面匹配的局限，實現對特定文化元素在相關文獻中深層關聯與流變脉絡的有效溯源。[②]

鑒於單一算法難以完美應對互文性分析的所有挑戰（如速度、精度、語義深度等），有效利用大模型强大的智能水平并結合多種方法的混合策略應當受到重視，將成爲一種重要的發展趨勢。這類策略通常是將速度快、覆蓋廣的檢索方法（如 N-gram、類 BLAST）用於初步篩選候選文本對，然後用精度更高但計算成本也更高的精細化方法（如詳細的序列對齊、深度學習語義匹配、LLM 驗證）進行確認、評分和深入分析。例如，前述李友仁（Paul Vierthaler）在其研究中便結合了類 BLAST 算法進行初步篩選和 Needleman-Wunsch 算法進行精確對齊。[③] 特别值得一提的是，有學者已經提出利用大語言模型進行互文分析，設計了“分割－規範化－合并”範式，整合了文本分塊、向量相似性搜索以及大語言模型驗證等多個環節。[④] 未來，通過靈活組合不同算法的優勢，有望實現更爲高效、精準和深刻的計算互

---

① Duan, S., Wang, J., Yang, H. et al. “Disentangling the cultural evolution of ancient China: a digital humanities perspective.” *Humanities and Social Sciences Communications*, vol. 10, no. 310, 2023. https://doi.org/10.1057/s41599－023－01811－x. 2025 年 5 月 29 日。

② https://chu.pkudh.net. 2025 年 5 月 29 日。

③ Vierthaler, P., & Gelein, M. (2019). A BLAST-based, Language-agnostic Text Reuse Algorithm with a MARKUS Implementation and Sequence Alignment Optimized for Large Chinese Corpora. *Journal of Cultural Analytics*.

④ Lau, Pak Kin, and Stuart Michael McManus. “Mining Asymmetric Intertextuality”. *arXiv*: 2410.15145 [cs. IR]. 2024. https://doi.org/10.48550/arXiv.2410.15145. 2025 年 5 月29 日。

中国知网 https://www.cnki.net

文性分析，從而更全面地揭示古典文獻之間複雜而多維度的關聯。

算法驅動的互文性研究實現了古典文獻分析範式上從局部比對到全域關聯的根本性轉移。傳統互文性研究受限於人力與認知範圍，往往聚焦於研究者已知的、有限的文本對或小範圍文獻群進行精細比對與個案分析，其視野本質上是局部的、點狀的。數字人文方法的介入，特別是文本相似度算法、序列比對技術、句子向量、大語言模型等技術的應用，使得研究者能够對海量古典文獻語料庫進行系統性、窮盡式的掃描與計算。同時，算法驅動的互文性研究所帶來的定量分析能力，能够提供客觀、可重複的量化指標，例如精確計算文本間的相似度得分、統計特定短語或主題的複用頻次及其在不同時代、不同文獻類型中的分布差異。

四　模式二：AI 賦能的文本分析研究

大語言模型作爲一種變革性工具，在文本生成、推理和理解方面展現出卓越的能力，爲古代文獻分析提供了前所未有的規模和深度的可能性。大語言模型在古代文獻研究中的應用，不僅僅是一場技術革新，更可能引發人文研究範式的轉變。傳統上，古代文獻研究往往依賴學者個人的深厚學養和獨立鑽研。大語言模型的出現，憑藉其處理海量數據、識别複雜模式、生成新假設以及提供多視角解讀的能力，正在推動研究工作流程的深刻變革。學者們不再僅僅是知識的獨立探索者，而轉變爲引導、驗證和綜合 AI 生成洞見的合作者與仲裁者。[①]

當前，一系列先進的大語言模型架構與技術正被積極探索與應用於古代文本分析領域。大模型長上下文與長文本輸出可以處理古代文獻的浩瀚篇幅并生成詳盡的摘要，從而實現對複雜叙事的深度分析。

---

① Ji, Wenlong, et al. "An Overview of Large Language Models for Statisticians." *arXiv*: 2502.17814 [stat. ML], 2025. https://doi.org/10.48550/arXiv. 2502.17814. 2025 年 5 月 29 日。

中国知网 https://www.cnki.net

基於檢索增强生成（RAG）技術，通過結合檢索模型與强大的生成式大語言模型，將模型的回答錨定於外部知識庫，顯著提升了在專業化、長尾知識領域的事實準確性并減少了“幻覺”現象。爲了克服現有大語言模型中潛在的以英語爲中心的偏見，文化背景融入（EmCei）技術采用兩步法，先提示大語言模型提取文化知識，再利用“大語言模型即評判者”機制篩選出文化上恰當的回應。[①] 此外，旨在模擬特定人物語言風格與思維模式的角色模擬（CharacterBot）框架，通過預訓練重構作者視角并結合 LoRA 等參數高效微調技術，在風格遷移和生成式問答等任務中展現了潛力。[②] 同時，假設驅動的個性化（HyPerAlign）技術能够從少量樣本中推斷用户或作者的特定屬性與假設，并利用這些假設來定制化大語言模型的輸出，適用於推斷作者特徵或生成研究假設。[③] 基於大語言模型的主題建模作爲一種新興方法，也被用於識别大型研究論文語料庫中的潛在主題結構，預示着其在分析古代文獻語料庫方面的廣闊應用前景。

表 2　大語言模型應用於古代文本解讀的各種角度

方法論/模型	核心原理/架構	優勢	局限性/挑戰	在古代文本中的應用方向
長上下文/長文本輸出 LLMs（Long-Context/Output LLMs）	擴展的上下文窗口，能够處理和生成更長的文本序列	處理複雜長文本，支持深度分析和推理	計算成本高，輸出連貫性和邏輯一致性仍需提升	處理冗長的古代文獻，生成詳細的闡釋性文本

① Koo, Hamin, and Jaehyung Kim. “Extracting and Emulsifying Cultural Explanation to Improve Multilingual Capability of LLMs.” *arXiv*: 2503.05846 [cs.CL], 2025. https://doi.org/10.48550/arXiv.2503.05846. 2025 年 5 月 29 日。

② Wang, Zixiao, et al. “Beyond Profile: From Surface-Level Facts to Deep Persona Simulation in LLMs.” *arXiv*: 2502.12988 [cs.CL], 2025. https://doi.org/10.48550/arXiv.2502.12988. 2025 年 5 月 29 日。

③ Garbacea, Cristina, and Chenhao Tan. “HyPerAlign: Hypotheses-driven Personalized Alignment.” *arXiv*: 2505.00038 [cs.CL], 2025. https://doi.org/10.48550/arXiv.2505.00038. 2025 年 5 月 29 日。

中国知网 https://www.cnki.net

續表

方法論/模型	核心原理/架構	優勢	局限性/挑戰	在古代文本中的應用方向
檢索增强生成（RAG）	結合檢索器從外部知識庫獲取信息，再由生成器生成答案	提高事實準確性，適用於專業領域，可驗證性强	依賴知識庫質量，檢索可能引入噪聲或不相關信息	可用於古典文獻領域的事實性問答，減少幻覺，提供可驗證的來源
文化背景融入	提示 LLM 提取文化知識，并使用 LLM 作爲評判者進行篩選	增强文化敏感性，緩解英語中心偏見	文化知識提取的全面性和準確性，評判者 LLM 的偏見	提升 LLM 在處理非英語或文化内涵豐富的古代文本時的準確性和恰當性
角色模擬	捕捉特定人物的語言風格和思維模式，通過預訓練和微調實現	能够生成具有特定風格和視角的文本，有助於理解作者意圖	深入思想和情感的捕捉仍具挑戰性，依賴高質量的個人作品數據	模擬古代作者的寫作風格和思想觀點，進行風格遷移和生成式問答
假設驅動的個性化	從少量示例中推斷文本（或作者）的特徵并形成假設，用於指導大語言模型生成	樣本高效，可解釋性强，適用於探索性研究	假設推斷的準確性，對少樣本的敏感性	推斷古代作者的寫作策略或世界觀，生成關於文本關係或歷史背景的研究假設
文本内容分析與闡釋	基於大規模預訓練，通過學習海量文本與推理，結合提示工程，進行深層語義理解與特徵提取	深度量化分析複雜藝術特徵與哲學概念；揭示模式、新視角；輔助闡釋、模擬與邏輯推演	事實性分析（如作者、時代背景）仍有不足；分析效果依賴模型能力與提示設計；可能存在模型偏見	文學作品藝術特色分析（意象、風格、模式等）；哲學文本思想内涵分析（概念、邏輯、闡釋等）；輔助創作與模擬闡釋研究；歷史文本中事件的梳理與解讀

中国知网　https://www.cnki.net

目前，利用大語言模型以這種模式對古典文獻進行的研究并不多，以下結合筆者正在參與的一些研究對 AI 賦能的文本分析研究模式進行簡單梳理。筆者注意到，在文學作品藝術特色分析、古代哲學文本思想分析方面，大預言模型展現出對古典文獻進行深度、量化分析的巨大潛力。傳統的詩歌鑒賞往往依賴於研究者的主觀經驗與感受力，而 AI 則能通過學習海量的詩歌文本及其相關評論，識别并分析其中複雜的藝術特徵，如意象運用、格律節奏、情感色彩、修辭手法乃至作者獨特的風格印記。例如，筆者所在團隊在詩歌模型方面的實踐（如其探討 AI 生成詩歌與人類創作相似度的研究），就利用詩歌鑒賞方法對模型生成的詩歌進行評估。[①] 目前各種主流大模型均能對古典詩歌或者生成詩歌進行“分析”，甚至可以判斷詩歌的“真僞”。在實踐中，筆者所在團隊發現，當前模型在詩歌作者、時代背景等事實性分析方面還有較大缺漏，但在藝術寫作手法等方面却表現出獨特的能力。在未來，大語言模型有望在揭示特定時期、流派或詩人作品中反復出現的模式與變異，甚至發掘出傳統研究所未能充分注意的細微藝術特徵，爲詩歌風格學、比較詩學等領域提供數據驅動的客觀參照與新的研究視角。

生成式模型在輔助創作研究方面開闢了新的路徑，尤其體現在利用真實詩歌語料生成模擬數據方面，也可以看作是大模型在文本分析方面的應用。古典文獻研究常面臨樣本有限或難以進行控制實驗的困境，而大型語言模型能够基於對真實古典詩歌的學習，生成大量風格、主題、形式可控的“模擬詩歌”或文本變體。爲了生成能够生成古詩的模型的訓練語料，鄧澤琨的學位論文利用對真實古詩進行翻譯、改寫、逆向生成創作提示（prompt）等操作，可以構建出多樣化

① Deng, Zekun, Hao Yang, and Jun Wang. “Can AI Write Classical Chinese Poetry like Humans? An Empirical Study Inspired by Turing Test.” *arXiv*: 2401.04952 [cs.CL], 2024. https://doi.org/10.48550/arXiv.2401.04952. 2025 年 5 月 29 日。

中国知网 https://www.cnki.net

的平行語料庫。[①]

針對哲學文本的深度分析，AI同樣能扮演關鍵的分析助手角色，尤其是在處理具有豐富哲學內涵與複雜闡釋史的概念時。傳統的哲學分析依賴於學者對文本的精讀、對歷史注疏的梳理以及邏輯思辨。大語言模型則可以通過處理大量相關文獻（包括原典、歷代注疏、現代研究），快速識別概念的核心要素，梳理其在不同語境下的用法變遷，并系統性地比較不同闡釋路徑的差異。這裏，筆者舉出對《逍遥遊》首章分析的一個小例子，利用此提示詞，借助大語言模型輔助分析大鵬與蜩鳩（小鳥）在“逍遥”實現上的不同條件與可能性，并精確對比郭象與支遁在逍遥義闡釋的論證邏輯與細微差别。通過該提示詞的引導（限於篇幅，以下提示詞采用簡潔版本），當前的各種主流大模型大都能够根據提供的文本，對莊子原文以及“大鵬與小鳥何者能逍遥”的四種邏輯組合進行推演，呈現出不同解讀視角下的論證脉絡。

…

請對莊子《逍遥遊》中的大鵬、小鳥何者可以逍遥進行分析，同時分析郭象逍遥義、支遁逍遥義的差異，判斷莊子、郭象、支遁的逍遥義應該屬排列組合中的哪一種？

大鵬、小鳥何者可以逍遥的排列組合有以下四種：

1. 大鵬可以逍遥，小鳥可以逍遥
2. 大鵬不可以逍遥，小鳥不可以逍遥
3. 大鵬可以逍遥，小鳥不可以逍遥
4. 大鵬不可以逍遥，小鳥可以逍遥

《逍遥遊》首章（略）

郭象《逍遥遊》首章注釋（略）

---

① 鄧澤琨《古詩的定制化生成和輔助創作——基於大模型的設計和實現》，北京大學碩士學位論文，2024年。

中国知网 https://www.cnki.net

支遁逍遥義（略）

…

需要注意的是，在探討 AI 賦能的文本分析研究邊界時，首要面臨的便是 AI 闡釋過程的“可解釋性”難題。當前，以大型語言模型爲代表的 AI 技術，其内部運作機制常呈現“黑箱”狀態，即便是模型設計者也難以完全追溯其得出特定闡釋結論的具體推理路徑和權重分配。同樣，在分析詩歌藝術特色時，模型識别出的“意象”“風格”等特徵，其判定的内部標準和決策過程不可解釋。

進一步來説，AI 賦能的文本分析研究還凸顯了“機器邏輯”（如果有的話）與傳統注疏方法論之間的内在張力。AI（特别是大語言模型）的長處在於處理大規模數據、進行模式識别、快速比對文本差異以及執行基於規則或概率的邏輯推理。然而，這種處理方式本質上是基於形式化、結構化和可計算化的邏輯。與之相對，中國古典文獻的傳統注疏不僅是字詞訓詁和義理闡發，更是一種蘊含深厚歷史語境、强調文本内在有機性與微言大義、注重闡釋者主體性與歷代學術傳承的綜合性人文實踐。因此，AI 基於其“機器邏輯”所進行的文本分析與闡釋，可能在效率和系統性上超越人力，但在處理文本的深層意蘊、歷史語境的複雜性，以及闡釋的創造性和人文關懷方面，與追求融貫性、歷史感和思想深度的傳統注疏範式之間存在本質差異與潜在衝突。

五　模式三：基於大模型的數據抽取

結構化數據抽取技術的演進，特别是從傳統依賴專家進行手動標注，到需要大量標注數據才可以訓練模型，一直到直接使用大語言模型進行更靈活、更多樣、準確性良好的信息抽取的跨越，正在深刻地重構古典文獻領域的知識生産方式，其核心在於使人文知識内容變得可計算、可分析。古典文獻蘊含着豐富的人物、時間、地點、事件、

中国知网 https://www.cnki.net

概念、制度等信息，但這些信息通常以非結構化的自然語言形式散布於文本之中。傳統方法通過人工閱讀、整理和編纂索引、年表、數據庫等方式進行結構化，過程漫長且成本高昂。傳統的機器學習算法，又需要大量的標注語料，才能取得較好的效果，而且嚴重局限在有較多語料的幾種標注方式上，較大地限制了數字人文方法的應用範圍。大模型憑藉其强大的上下文理解和生成能力，通過精心的提示工程或模型微調，有望實現對文獻中各類實體及其關係的快速、批量抽取，自動構建結構化的數據集。研究者可以基於這些結構化數據進行量化分析、網絡可視化、模式挖掘等各種數字人文研究，從而發現宏觀層面的歷史規律、社會結構或思想脉絡，推動研究從單一文本的深度解讀走向跨文本、數據驅動的知識發現。

由於數據抽取本身是自然語言處理的重要任務，從大語言模型出現伊始，學者們就嘗試將大模型運用在古代文獻數據抽取領域，通過一系列不斷演進的方法論與關鍵技術驅動發展，旨在克服古漢語的語言獨特性、數據稀缺性以及模型固有局限性等挑戰。核心策略包括針對古漢語優化模型架構與微調，例如開發“荀子”等領域專用模型或在通用模型（如 Qwen，GLM，Llama）基礎上利用古籍語料庫進行持續預訓練和高效微調（如 LoRA、多任務學習、SFT 相結合的兩階段訓練）。[①] 爲提升在專門任務和低資源環境下的表現并減少幻覺，提示工程（如多階段提示、思維鏈）與檢索增强生成（RAG）技術（特别是知識圖譜驅動的 GraphRAG）被廣泛采用，後者通過將大語言模型輸出錨定於外部事實信息來增强可靠性。同時，大語言模型被積極應用於自動化構建古籍知識圖譜，從文獻中提取實體與關係，尤其在傳統中醫和歷史文獻等領域，通常結合定制化提示與人工審核進行知識融合與標準化。新興的多模態大語言模型（MLLMs）則可用於處理數

① Dongmei Zhu, Chang Liu, Xue Zhao, Zhixiao Zhao, Si Shen, Dongbo Wang, XunZi-MLLM: a multimodal large language model for ancient text and image recognition, *Digital Scholarship in the Humanities*, 2025; https://doi.org/10.1093/llc/fqaf026

中国知网 https://www.cnki.net

字化古籍或包含視覺元素的文獻，通過整合文本與圖像信息，拓展了古籍數字化與分析的邊界，促進了對文化遺產更全面的理解。

表 3 大語言模型在數據抽取方面的應用方法對比

方法/技術	算法/技術核心	原理/架構	主要優點	主要局限性	應用場景
針對古漢語的大語言模型架構與微調	領域專用大語言模型，通用大語言模型微調(LoRA,SFT)	優化模型以適應古漢語特性及領域知識	提升古漢語處理性能，更好理解語義	需大量數據與算力；通用模型初始表現差	古籍理解、詞法分析、標點、專門文獻分析、古文文本生成
檢索增强生成（RAG）與 GraphRAG	向量數據庫，檢索算法，知識圖譜（KG）集成	大語言模型生成前從外部知識庫檢索信息增强上下文。	減少幻覺，提高準確性，利用外部知識	檢索質量影響生成；知識庫維護成本高	事實問答、傳記生成、減少内容虛構
利用大語言模型構建知識圖譜	大語言模型自動標注（實體、關係提取），知識融合	用大語言模型從文獻中自動提取結構化知識	加速知識圖譜構建，降低人工成本	大語言模型提取可能不準，需大量人工審核；歧義處理難	構建領域知識庫，語義化文獻，數據關聯
提示工程(Prompt Engineering)	零/少樣本提示，思維鏈（CoT），定制化提示	通過精確指令引導大語言模型行爲，無需重訓練	成本低，靈活，快速適應新任務，利於低資源場景	提示設計依賴技巧，可能不穩定	知識圖譜構建（實體、關係提取），低資源 NER，特定文本生成
多模態大語言模型（MLLMs）在古籍數字化與分析中的進展	視覺語言模型，圖文聯合處理	整合處理文獻中的文本與圖像信息	處理影印本、插圖文獻，拓展分析維度	技術發展初期，訓練複雜，成本高；圖文深層融合難	古籍影印本數字化、圖文分析、文物信息提取、綜合文化遺産研究

中国知网 https://www.cnki.net

以下結合筆者正在參與的一些研究對基於大模型的數據抽取模式略舉一二例。在數智時代背景下，古典文獻研究模式的轉型與重構迫切需要高效的數據處理與知識發現能力，因爲以大語言模型爲支撐的數據抽取技術帶來了更大的靈活度，能够實現古典文獻知識的更複雜的結構化與知識挖掘。基於大模型的數據抽取通過利用大語言模型强大的自然語言理解、信息抽取與生成能力，將蘊藏在海量非結構化或半結構化古典文獻中的隱性知識顯性化、碎片信息系統化。在知識抽取層面，可針對特定研究目標設計抽取任務。例如，北京大學數字人文中心團隊正在嘗試從《全唐詩》等大規模詩歌語料庫中，自動識别并標注詩歌意象（如“月”“柳”“邊塞”）、情感基調（如“豪放”“婉約”“憂愁”）、藝術手法（如“比喻”“用典”）等標籤。通過預先定義的標籤體系或利用模型的零樣本/少樣本學習能力，大語言模型能够解析詩句的深層語義，捕捉文學要素，并將其轉化爲結構化的數據，即具備明確語義、格式和標籤，可被高效利用和分析的數據。

進一步地，數據抽取還可以超越單一的文本模態，拓展至多模態内容的智能抽取與分析，致力於打通文本、圖像等多種古典文獻載體間的信息壁壘。借助多模態大模型的發展，可以從古代繪畫、器物、輿圖等視覺材料中抽取結構化信息。以古代畫作風格分析爲例，可以利用具備圖像識别能力的大語言模型分析畫作（如宋代蘇漢臣《妝靚仕女圖》），[①] 自動識别并標注畫面中的元素（人物的服飾與姿態、建築樣式、植物種類、器物細節）、色彩運用、筆法特徵（綫條粗細、墨色濃淡）、構圖布局等，并將其整理爲結構化數據。

基於大模型的數據抽取，正以其顛覆性的潜力塑造着數智時代古典文獻研究的新範式，其關鍵突破在於將研究者從傳統的手動標注這一耗時費力的基礎工作中解放出來。傳統的自然語言處理技術高度依賴大量精標注的數據，因此只能在少量常見自然語言處理任務上進行，如分詞、命名實體識别等。大語言模型的引入，能够自動化、規

① https://help.wuyudian.net/docs/case-song-painting.html，2025 年 5 月 7 日訪問。

中国知网　https://www.cnki.net

模化地執行各種數據抽取任務，專家學者只需要根據研究任務對抽取任務進行定義，僅提供少量樣本，甚至不需要提供樣本，就能够從海量詩詞中批量抽取意象、情感、格律等標籤，或在複雜的歷史文獻中自動識别人物、地點、時間、事件等結構化信息。更深層次地，基於大模型的數據抽取可以將大量原本以定性描述爲主、難以直接進行計算分析的人文數據轉化爲可量化、可計算的結構化數據格式，從而大大拓展了研究方法的邊界。針對古典文獻的傳統研究方法側重於細讀與闡釋，難以進行大規模的統計分析。通過應用大模型進行知識抽取，那些原本難以捉摸的文化信息具備了計算可行性。

六　結語

本文根據人文研究的規律與當前人工智能發展水平，嘗試歸納出面向古典文獻研究的三種研究模式——算法驅動的互文性研究、AI賦能的文本闡釋研究，以及大模型支持的數據抽取，以便利用這些研究模式開展有關數字人文研究。這些研究模式是在古典文獻整理之外，針對古典文獻的數字人文研究提出的方法論思考。

數智化研究模式的引入，特别是自動化、智能化工具的應用，正帶來古典文獻研究領域深刻的學術生産力解放。傳統研究中大量耗費學者精力與時間的環節，如海量文獻的人工瀏覽與篩選、繁瑣的版本對勘、基礎信息的重複性標注與統計等，如今可借助高精度 OCR、自然語言處理、機器學習算法乃至大語言模型高效完成，縮短了數據準備與初步分析的周期。

可以説，數智時代古典文獻的研究範式正在從“細讀”（close reading）到“遠讀”（distant reading），進而邁向“智能讀”（intelligent reading）。傳統的“細讀”專注於文本内部的精微之處與個案深度，而以計算方法爲基礎的“遠讀”則轉向宏觀模式與整體關聯。如今，以 AI 爲核心的“智能讀”則試圖在更高層次上融合二者：隨着上下文窗口的進一步增大，它不僅能處理大規模數據（“遠讀”），還

中国知网 https://www.cnki.net

能借助 AI 的語義理解與生成能力（“智能讀”），輔助進行更深入、更精細的文本分析與闡釋（“細讀”）。“智能讀”利用機器智能放大并延伸了人類的閱讀與思考能力，使得在宏觀視野下，同時進行一定深度的研究成爲可能，預示着一種新的人工智能輔助的文獻解讀新範式。

數智技術與古典文獻研究的深度融合，必然要求對傳統的研究流程進行重構，形成人機協同的新型工作模式，明確學者與算法（或人工智能）之間的合理分工與高效協作。在這一新流程中，算法與人工智能模型憑藉其强大的計算能力、模式識别優勢和處理海量數據的效率，主要承擔起文獻的數字化、結構化信息抽取、大規模文本比對與關聯發現、初步模式識别與量化分析等任務。而學者則發揮其在問題意識、理論框架構建、研究設計、複雜語境理解、批判性思維，以及最終意義闡釋等方面不可替代的作用。學者需要界定研究問題，選擇和訓練合適的模型，設計有效的提示詞，解讀并審視機器生成的初步結果，結合領域知識進行深度分析與理論升華，并對整個研究過程的有效性與局限性進行反思。

然而，在擁抱數字人文帶來的範式革新時，必須審慎處理作爲工具的技術與傳統人文學科核心價值之間的平衡關係。數字人文方法，特别是計算分析和數據驅動的研究路徑，無疑增强了研究的客觀性、精確性和可重複性，體現了强大的“研究”力量。過度强調技術和量化指標，可能導致研究問題的窄化，對複雜歷史文化語境的忽視，以及對人文研究所追求的深層意義、價值關懷與批判性反思的削弱。因此，數智時代的古典文獻研究轉型，絶非以技術取代人文，而應是以技術賦能人文。

[作者單位] 楊浩：北京大學人工智能研究院

中国知网 https://www.cnki.net