

高邮二王考据过程知识库构建及应用

高邮二王考据过程知识库构建及应用

赵梓名（组长）、廖展慧、卢飞宇、李汶灿、徐健怡

高瓴人工智能学院 / 信息学院 / 明德书院 / 文学院

2026 年 5 月



中國人民大學
RENMIN UNIVERSITY OF CHINA

汇报结构

- ① 问题与对象
- ② 学术框架
- ③ 数据库与网站
- ④ 多模态与泛化
- ⑤ 计划与成果



① 问题与对象

② 学术框架

③ 数据库与网站

④ 多模态与泛化

⑤ 计划与成果



从“查得到”到“看得懂”

现有平台

- 影像浏览、全文检索、条目定位
- 解决“材料在哪里”的问题
- 更偏向对象知识和文本入口

我们的切入点

- 一条考据怎样成立
- 证据如何组织，旧说如何裁断
- 保存方法知识和过程性知识

不再做一个古籍入口，而是复原判断链条。

为什么是高邮二王

- 高邮王念孙、王引之是乾嘉学派代表人物，“王氏四种”集中呈现清代考据学成熟方法。
- 材料边界清楚：《广雅疏证》《经义述闻》《经传释词》《读书杂志》适合一年周期集中推进。
- 方法类型集中：讹字、通假、因声求义、联绵词、虚词释读、句法辨析等反复出现。
- 适合跨学科表达：传统小学、文献学问题可以转化为结构化数据、检索界面和AI 辅助流程。

清代考据

训诂学

经学解释

数字人文

古典人文学术与现代数智技术的融合

古典人文学术

文献细读、出处核验、训诂判断、效度辨析。

数据组织

字段设计、SQLite、快照导出、前端检索。

智能辅助

相似案例召回、证据匹配、结构草稿、人工复核。

答辩重点

校勘学、训诂学等古典人文学术不是单独讲一套术语，而是作为数据建模和人工复核的规则；现代数智技术也不是包装层，而是让研究过程可展示、可复核、可扩展。

① 问题与对象

② 学术框架

③ 数据库与网站

④ 多模态与泛化

⑤ 计划与成果



一条考据的结构（据《训诂学原理》）



- 发疑：旧注分歧、字义不通、语境不合。
- 预设：<>
- 取证：书证、声训、义证、形证、异文、语法证据。

- 释理：说明证据为何能推出结论。
- 结论：确证、倾向性假说、待核。
- 类推：<>

训诂学内容怎样进入系统

学术概念	系统中的落点
声训、通假	进入方法标签、证据类型和核对事项
形训、义训	进入释理说明和结论边界
词义训释 / 文意训释	帮助区分稳定义项与具体语境解释
望文生训	作为旧说裁断、反证说明和风险提示
形音义互求	作为同类案例比较的基本观察框架

训诂学不是装饰性背景，而是判断“数据是否可信”的规则。 1937

代表案例：“造舟于河”

争点

《经义述闻·左传下》讨论“造舟于河”：这里的“造”应训为**比次**，还是训为**至**？

- 《正义》承认“比舟为梁”，却转训“造”为“至”。
- 王念孙提出：“造之言曹也，相比次之名也。”
- 问题被收束为可证的训释命题。
- “造、次一声之转”。
- “蒞”有副、次之义。
- 薛综注《东京赋》“以舟相比次为桥”可作旁证。

发疑


立说

取证

释理

裁断旧说

流程图：把个案转化为可复核结构



图示来自当前网站首页流程图，用于说明“发疑—设问—取证—释理—结论”的组织方式。

① 问题与对象

② 学术框架

③ 数据库与网站

④ 多模态与泛化

⑤ 计划与成果



五类对象承接考据过程

对象	保存内容	展示作用
著作	二王著作、经典、工具书来源	保证出处可追溯
条目	原文、引文、二王论述片段	支持后续精细定位
词目	字、词、术语和义项摘要	提供检索入口
案例	问题、方法、过程、结论、状态	保存考据主体
证据	书证、声训、义证、异文等	支撑复核与比较

词条是入口，案例是中心，证据和出处保证可复核。

当前数据基础

49

著作来源

3385

词条

815

案例

7120


证据

人工标注灰度库


当前另有 3 个标注文档、17 条案例、44 个词条、121 条证据、64 个过程步骤。主库用于展示相对稳定成果；标注库用于保存工作稿、AI 整理与人工复核材料。

两条数据管线

主库管线




标注库管线



成熟成果与研究工作稿分离，避免把待核材料混入主库。

网站页面：多种材料形态共同展示

- 首页：用“造舟于河”讲清一条考据。
- 数据库页：字词、案例、结构三种视角。
- 详情页：展开证据链和出处。
- 术语页：辅助理解训诂概念。
- 人工标注库：展示 DOCX 标注转出的结构化成果。
- AI 释证：输出草案，同时展开引用材料。



<https://gaoyou-demo1.up.railway.app/>

① 问题与对象

② 学术框架

③ 数据库与网站

④ 多模态与泛化

⑤ 计划与成果



这里的“多模态”是什么意思

不是只做文本检索

本项目同时处理多种材料形态，并让它们在同一条案例中互相指向。

文本

原典、引文、二王论述、现代整理说明。

结构

字段、表关系、证据类型、过程步骤。

界面

流程图、数据库页、详情页、引用展开、AI 草案。

[原文](#)[批注](#)[JSON](#)[SQLite](#)[网页](#)[AI 输出](#)

AI 的位置：可核对的辅助

可以辅助

- 相似案例召回
- 证据片段匹配
- “立论—取证—释理—结论”草稿
- 提醒人工复核点

不能替代

- 原文与版本核对
- 通假方向判断
- 词义与文意区分
- 最终学术结论

AI 不做裁判，只做可追溯材料上的助手。

泛化能力

可迁移的不是页面，而是方法

只要研究对象具有“疑点—证据—论证—结论”的结构，就可以迁移这套整理框架。

- 段玉裁《说文解字注》知识整理
- 清代考据笔记与校勘札记
- 经传注疏争议条目
- 其他专书训释材料
- 课堂阅读训练平台
- 人机协作标注流程

案例粒度

证据类型

过程标注

人工复核

① 问题与对象

② 学术框架

③ 数据库与网站

④ 多模态与泛化

⑤ 计划与成果



阶段计划

阶段	任务	产出
A	统一底本、出处、案例模板和术语口径	字段规范、首批案例清单
B	完成基础录入、检索、词条页和案例页闭环	基础检索原型
C	扩充精校案例，比较典型疑难处理路径	不少于 60 条代表性案例
D	探索 AI 辅助召回、证据匹配和草稿生成	AI 辅助分析说明

预期成果

项目交付

- 不少于 60 条代表性二王案例精校整理
- 《二王考据案例标注规范》
- 可演示的案例检索原型

研究产出

- 典型疑难处理路径整理说明
- AI 辅助分析实验说明
- 阶段性研究报告或论文初稿

总结

本项目不是再做一个古籍检索入口。

它尝试证明：

传统考据过程可以被结构化、复核化、平台化。

学术可追溯

数据可扩展

方法可泛化